# DCGAN, PGGAN, StyleGAN

DCGAN, PGGAN, StyleGAN 논문리뷰

2022.10.18 학부연구소모임 우아라

---

▼ 22.10.18

1. **DCGAN의 경우**, 기존 GAN 에서 fully-connected layer 구조를 사용하지 않고 convolutional and deconvolutional layer로 대체했다는 구조를 이해하고, 한계점으로 (1) 고해상도 영상을 생성하기 어려움, (2) min-max problem을 해결하는 과정에서 학습이 불안정함 (3) GAN에서 BCE loss를 사용하면서 생성자가 유사 영상만 만들어 내는 model collapse (모드 붕괴) 현상 발생 등이 있단다.
2. **PGGAN의 경우**, 점진적으로 layer를 추가하여 low resolution에서 high resolution 영상을 생성가능하게 하여 1024x1024 영상까지 생성하게 함. 점진적으로 layer를 추가하여 학습하기 때문에 학습이 안정적임. 고해상도 영상을 상대적으로 안정적으로 생성할 수 있는 장점이 있는 반면 원하는 특정 feature에 대한 생성은 어려워서 style transfer에 기반한 generator 구조를 제시한게 StyleGAN 이 됨.
3. **StyleGAN의 경우**, 최종 생성된 영상을 style들의 조합으로 생각해서 generator의 각 layer 마다 style을 입히는 방식으로 영상을 만들어내는 것으로 초기 layer는 coarse feature를 만들어내고 뒤로 갈수록 fine detail을 만드는 등 visual attribute를 조절할 수 있다는 게 가장 큰 차이점임.
4. 위 사항을 참고하여 의료영상 분류 문제에서 데이터증강을 위해 사용한 DCGAN, PGGAN 에서의 한계점을 기재해 놓은 것이 있으면 해당 사항이 함께 논문에 기재되는게 좋단다.
5. 코드리뷰를 해보겠다는 사항은 1x512 input latent vector를 입력받아 mapping network (fully-connected layer 8개 통과)에 넣어서 disentanglement 한 intermediate latent vector W를 만들어내고, 각기 다른 w 벡터를 AdaIN layer에 넣어서 style을 입히는데 이 때 세부 사항들을 변경시키기 위해서 noise를 추가한다고 생각하면 되고 최종으로 PGGAN과 동일하게 1024x1024 영상을 생성함.

▼ 22.10.25

- [x] ~~코세라 강의 듣기~~
- [x] ~~DCGAN의 한계와 min max problem을 해결하는 과정에서 학습이 불안정한 이유. (Mode collapse, Mode의 뜻)~~
- [x] ~~binary cross entropy loss에 대한 WGAN-GP loss 사용 시 안정적으로 학습하는 이유~~
- [x] ~~PGGAN 구조 - (a),(b),(c) 설명~~
- [x] ~~Batch normalization, instance normalization 차이, 그림 첨부~~
- [x] ~~AdaIN 공식의 ysi, ybi 설명~~
- [x] ~~AdaIN 코드의 feature 3가지 shape 이해~~

---

# DCGAN

**[Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks]**

https://arxiv.org/pdf/1511.06434.pdf

---

## DCGAN?

- 기존 GAN의 이미지 퀄리티를 높임
- Black-box method 문제를 어느정도 해결

- Generator가 단순 기억으로 generate 하지 않는다는 것을 보여줌
- z의 미세한 변동에 따른 generate 결과가 연속적으로 부드럽게 이루어져야 한다. (walking in the latent space)
- 벡터 연산 가능

---

## DCGAN 구조

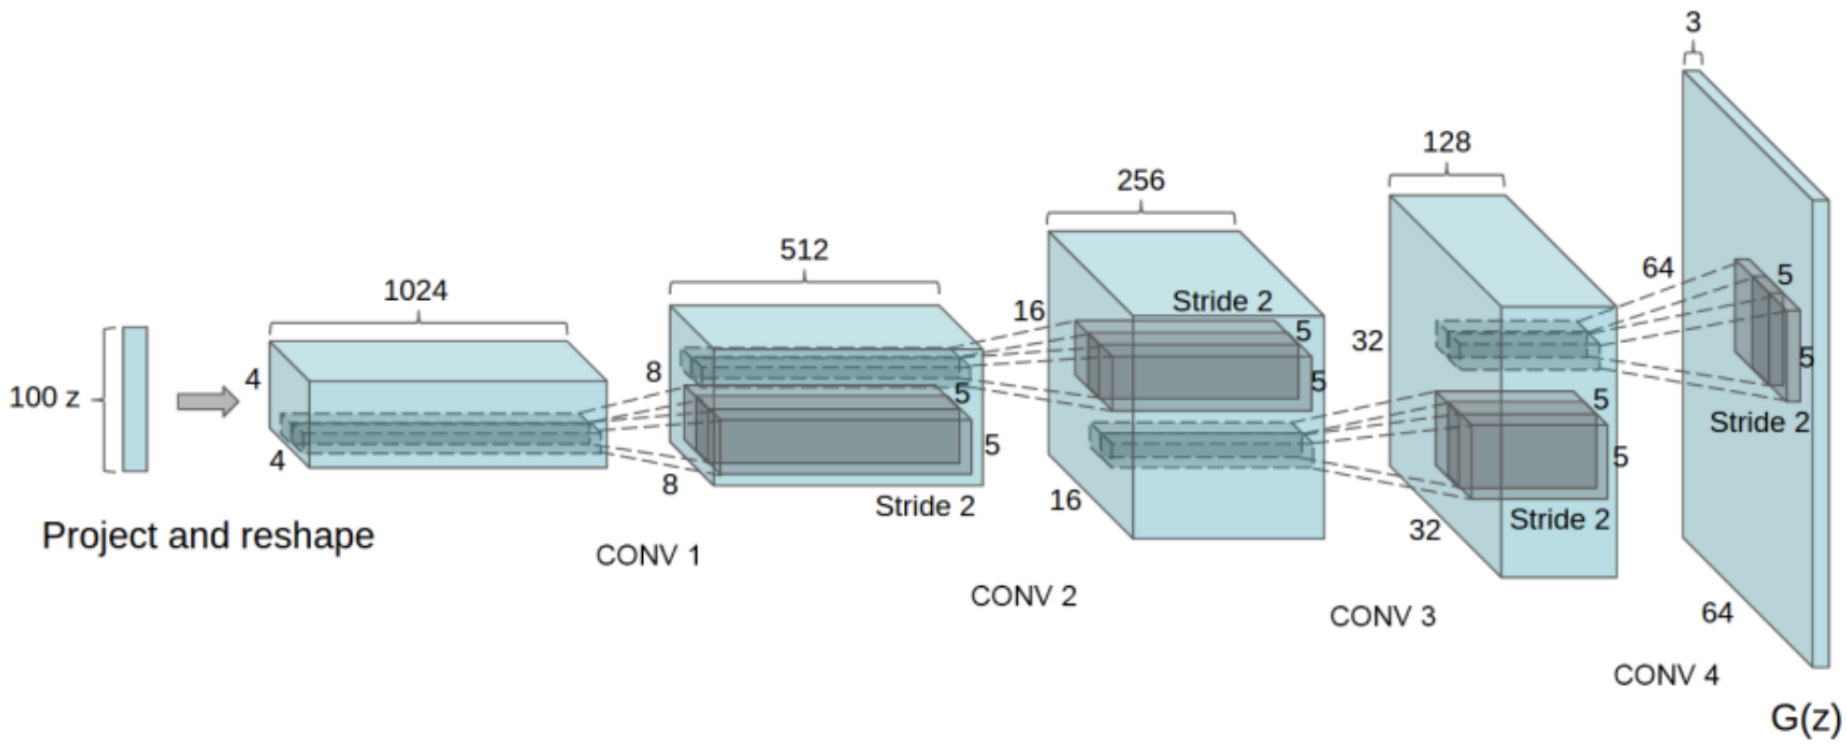


Architecture guidelines for stable Deep Convolutional GANs

- Replace any pooling layers with strided convolutions (discriminator) and fractional-strided convolutions (generator).
- Use batchnorm in both the generator and the discriminator.
- Remove fully connected hidden layers for deeper architectures.
- Use ReLU activation in generator for all layers except for the output, which uses Tanh.
- Use LeakyReLU activation in the discriminator for all layers.

- pooling layer 대신 **stride & fractional-stride convolution layer** 사용
- Generator와 Discriminator 에 **Batch normalization layer** 사용
  - 깊은 신경망일수록 같은 Input 값을 갖더라도, 가중치가 조금만 달라지면 완전히 다른 값을 얻을 수 있다.
  - 이를 해결하기 위해, 각 layer에 배치 정규화 과정을 추가해준다면, 가중치의 차이를 완화하여 보다 안정적인 학습이 이루어질 수 있다.
- Fully connected layer 제거
  - 파라미터를 너무 많이 잡아먹어 계산량이 늘어나기 때문
  - 3차원 이미지를 1차원으로 평탄화하면 공간 정보가 소실되기 때문
- Generator에 **ReLU** 사용 + 마지막에 **Tanh** 사용
  - ReLU : 0보다 작으면 0, 0보다 크면 그대로 출력 (Gradient vanishing 현상 해결)
- Discriminator에 **Leaky ReLU** 사용 + 마지막에 **Sigmoid** 사용

---

## DCGAN 한계

- 고해상도 영상을 생성하기 어려움,
- min-max problem을 해결하는 과정에서 학습이 불안정함

- GAN에서 BCE loss를 사용하면서 생성자가 유사 영상만 만들어 내는 mode collapse (모드 붕괴) 현상 발생

+) mode collase가 발생하는 이유

훈련 중에 모델이 불안정하고 훈련하는 데 상당한 시간이 걸릴 수 있고, 경사 하강법이 항상 필요한 discriminator을 가져다 주지 않는다.

→ 이를 WGAN loss와 립시츠 연속성으로 해결

+) **mode**

mnist 숫자 데이터(0~9)로 예를 들면, mode는 0~9 이고, 데이터의 분포가 특정 숫자(mode)에 치우칠 때, mode collapse가 발생했다고 말한다.

---

# PGGAN(=ProGAN)

**[PROGRESSIVE GROWING OF GANS FOR IMPROVED QUALITY, STABILITY, AND VARIATION]**

https://arxiv.org/pdf/1710.10196.pdf

## PGGAN?

- 그 전의 GAN들은 고해상도 이미지를 만드는 것이 매우 힘들었는데, 새로운 접근 방법으로 **고해상도 이미지 생성**에 성공
- 학습이 안정적(**WGAN-GP** Loss 적용)
- 학습 시간 절약

+) **WGAN-GP (Wasserstein GAN Gradient Penality)**

실제 이미지와 가짜 이미지를 비교하기 위한 방법으로 픽셀 간의 거리를살펴 loss를 판단하는 방법이 있다. 하지만 이미지가 비슷하더라도, 픽셀이 이동한 경우 픽셀 거리가 멀어질 수 있다.

**binary cross entropy**는 generator의 fake sample이 실제 입력에서 멀리 떨어져 있을 경우 generator을 훈련시키는 데 사용되는 기울기의 소실 문제가 발생할 수 있다.

→ 이 문제를 해결하기 위해 WGAN-GP을 사용한다.

WGAN은 데이터 분포간의 측정 방법으로 Wasserstein distance를 사용한다.

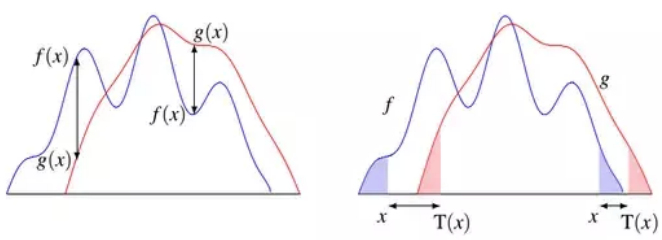


WGAN에서 generator은 같은 방식으로 정의하고, 1)discriminator의 손실 함수에 gradient penality 항을 포함하고, 2)discriminator의 가중치를 clipping 하지 않고, 3)discriminator에 배치 정규화 층을 사용하지 않는 **WGAN-GP**이다.

▼ WGAN-GP 수식

https://arxiv.org/pdf/1704.00028.pdf

$$\min_G \max_{D \in \mathcal{D}} \mathop{\mathbb{E}}_{\boldsymbol{x} \sim \mathbb{P}_r} \left[ D(\boldsymbol{x}) \right] - \mathop{\mathbb{E}}_{\tilde{\boldsymbol{x}} \sim \mathbb{P}_g} \left[ D(\tilde{\boldsymbol{x}}) \right]$$

D : 1-Lipschitz function의 집합 (***두 점 사이의 거리를 일정 비 이상으로 증가시키지 않는 함수***)

Pg : ~x=G(z), z~p(z) 에 의해 정의된 모델의 분포

최적의 discriminator 하에, generator 파라미터에 관련된 value function을 최소화 → W(Pr,Pg) 최소화

▼ WGAN-GP 코드

```
def r1_gradient_penalty(y_true, y_pred, samples, sample_weight):
    #Get gradients of pixel values (first layer)
    gradients = K.gradients(y_pred, samples)[0] # 입력에 대한 손실의 그래디언트 구하기 grads = K.gradients(loss, model.input)

    #Get norm squared: ||grad||^2
    gradients_sqr = K.square(gradients) #제곱
    gradient_norm = K.sum(gradients_sqr, axis = [1, 2, 3])  #평균 계산

    #Return average over batch
    return K.mean(gradient_norm)
```

---

## 기존 GAN들이 고해상도 이미지를 만들기 어려웠던 이유

- High Resolution 일수록 Discriminator는 Generator가 생성한 Image가 Fake Image인지 아닌지를 구분하기가 쉬워진다.
- 고해상도 이미지를 잘 만든다고 해도, 메모리 제약 조건 때문에 mini-batch size를 줄여야 한다. batch size를 줄이면 학습과정 중 학습이 불안정해지는 현상이 발생한다.

---

## PGGAN 구조

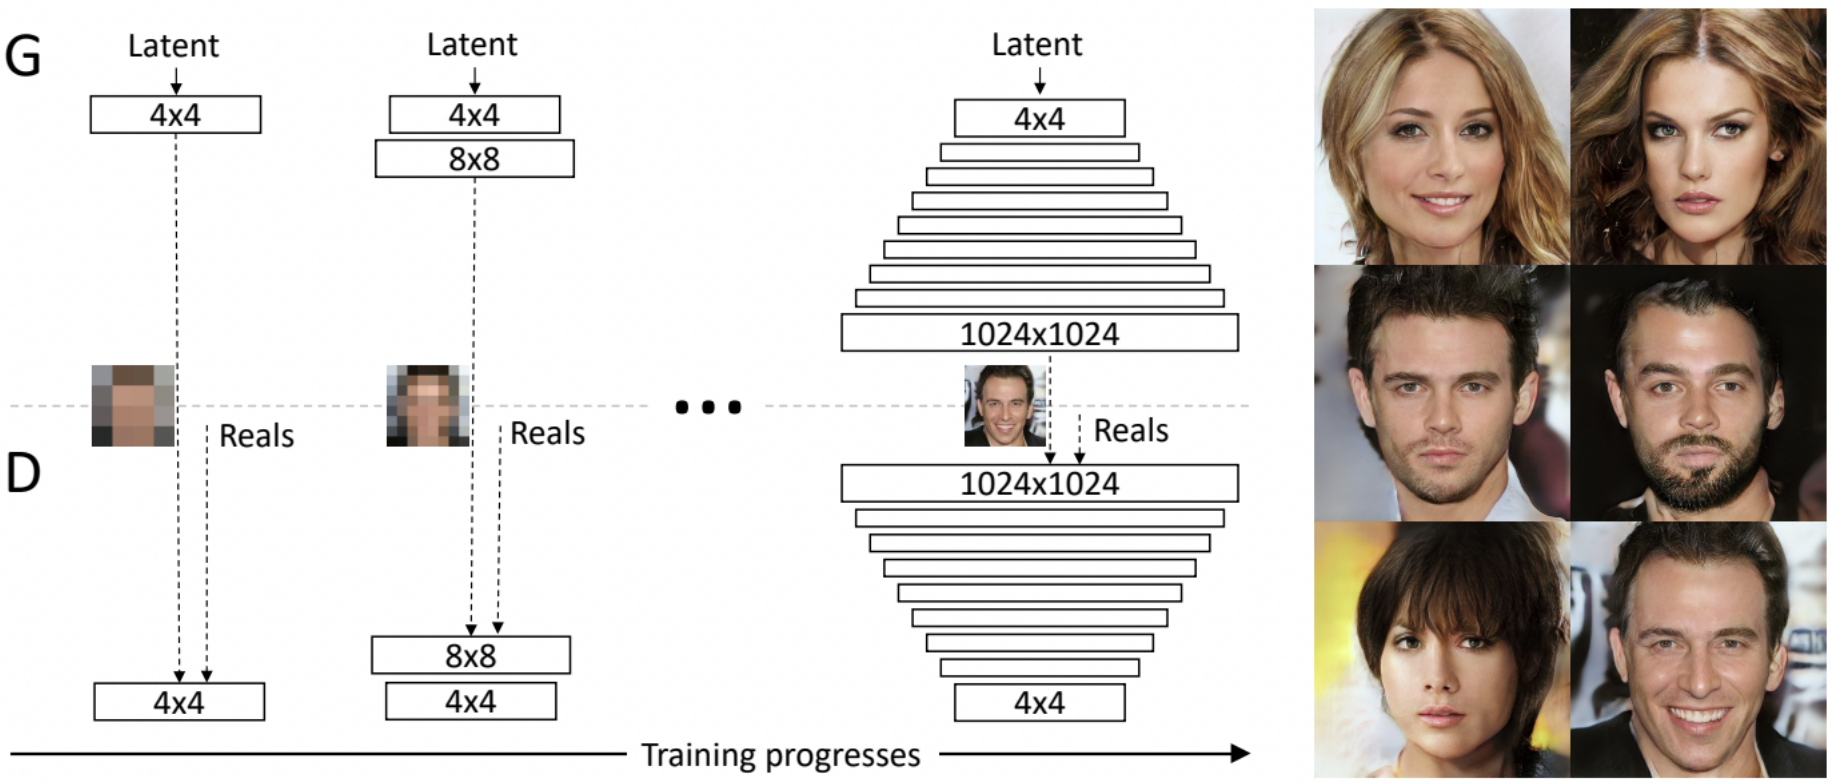


- 점진적으로 Generator와 Discriminator를 키운다. (Low resolution 에서 High resoliution으로 키우기 위해서 layer를 점진적으로 add해 주는 것)
  - 점진적으로 layerd을 add 할 때의 장점

    Image Distribution(각 이미지마다 분포가 다 다름)에서 Large scale 구조(전반적인 전체 데이터 형태)를 먼저 발견하도록 도움을 준다.

    점차 레이어를 쌓아 올라갈수록 세부적인 Feature들을 보면서 학습을 진행한다.
- 새로 추가하는 레이어를 smooth하게, fade in 하게 넣어준다

  (이미 잘 학습된 이전 단계의 layer( n-1 layer)들에 대한 sudden shock를 방지)

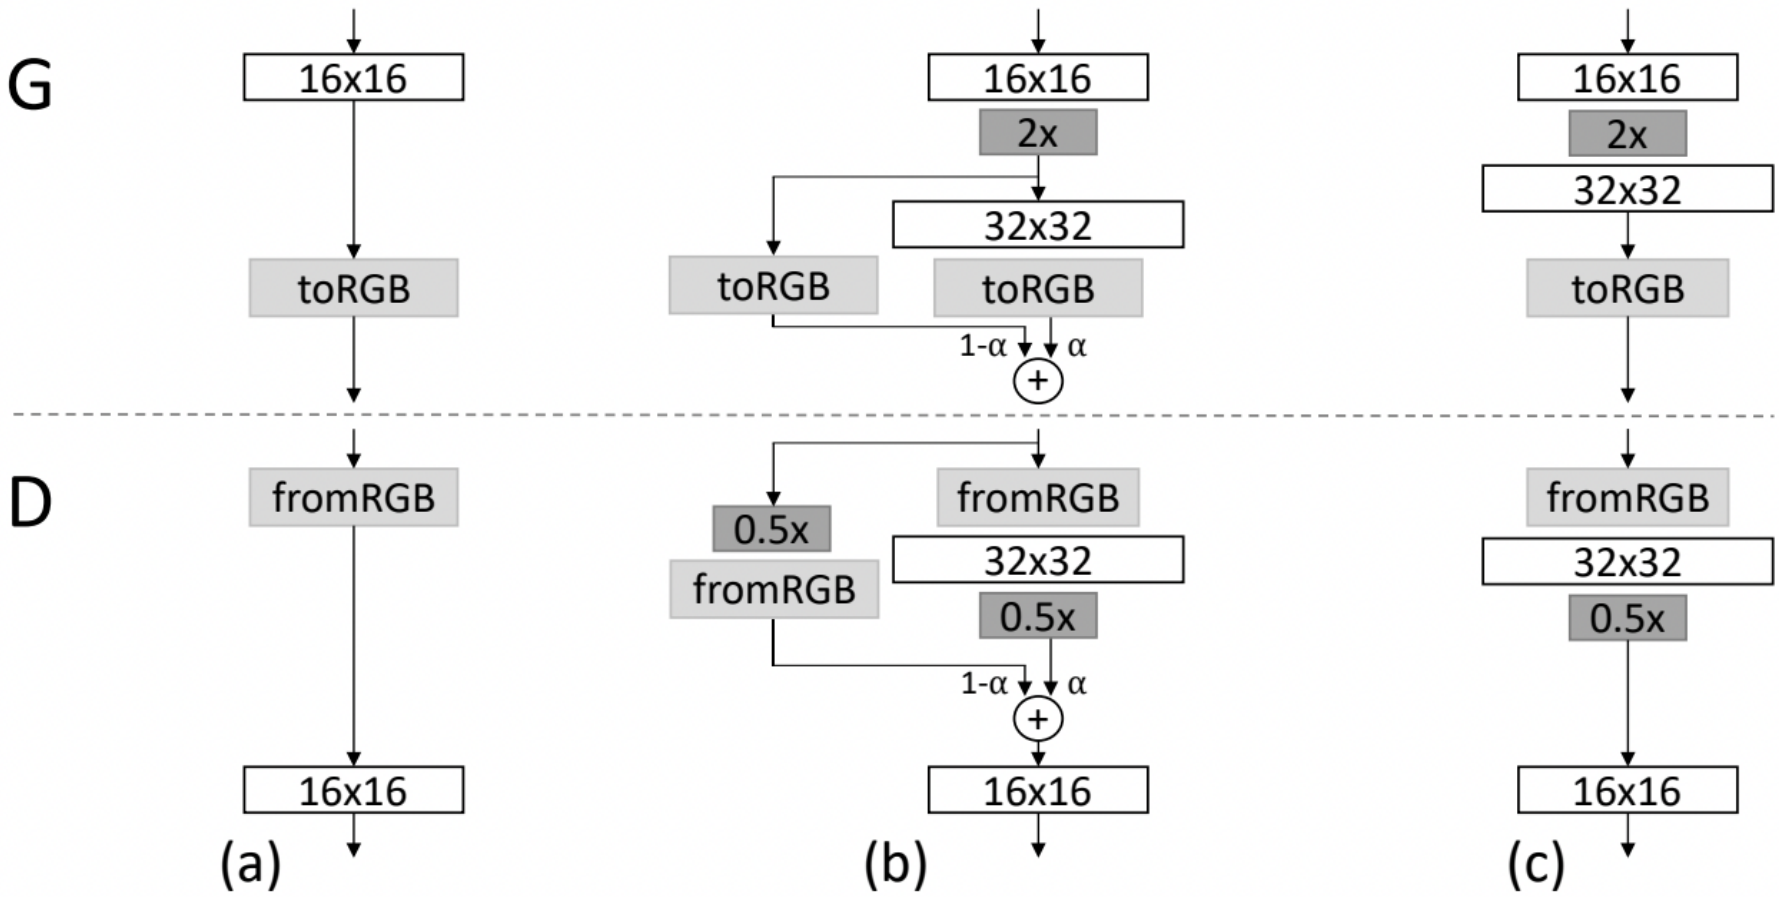


- 2x : 이미지의 해상도 두 배 늘림
- toRGB : Feature Vector를 RGB Color로 만듬
- smooth fading in

  (a) 16x16 해상도의 RGB 이미지를 만들었을 때, 곧바로 32x32 해상도를 학습시키면 학습이 전혀 안 된 32x32 layer의 간섭으로 잘 학습된 저해상도 layer까지 영향을 미치게 된다. 따라서 부드럽게 layer을 끼워넣는 방식 (smooth fade in) 이 필요하다.

  (c) 그냥 32x32레이어만 끼워넣는 것이 아니라, 16x16으로 만들어낸 이미지를 2배로 늘린다. , 저해상도 이미지의 스케일만 늘려서 대략적인 형태를 지닌 이미지를 만들어낸다.

  그리고 32x32에서 만들어낸 이미지를 잘 학습된 저해상도 이미지와 합친다.

  (b) 이미지를 합칠 때, 각 픽셀 값에 1~0 사이의 비율을 나타내는 $a$를 곱하고 저해상도 픽셀에는 그 나머지 비율을 뜻하는 1-$a$를 곱해서 서로 더해주면, 저해상도의 큰 그림과 앞으로 학습시킬 고해상도의 디테일이 합쳐진다.

  Discriminator에서는 학습 되지 않은 32x32, 저해상도로 학습된 16x16을 같은 방식으로 학습한다.(여기서 $a$는 0~1 로 증가한다.)

---

### PGGAN 한계

- 원하는 특정 feature에 대한 생성은 어려움 (이미지의 특징 제어가 어려움)
- 이미지의 특징이 잘 분리되어 있지 않기 때문에 다른 특징까지 개입되는 문제 발생

(Generator에 latent vector z가 바로 입력되게 때문에 entangle하게 되어서 style의 변형이 불가능 하다.)

---

## StyleGAN

코드리뷰에서는 input vector의 크기, 출력영상의 크기, AdaIN의 역할, noise의 역할 및 noise를 어떻게 주었는지 등에 대해서 확인 및 질문

**[A Style-Based Generator Architecture for Generative Adversarial Networks]**

https://arxiv.org/pdf/1812.04948.pdf

### StyleGAN?

- 고화질 이미지 생성에 적합한 아키텍처 제안

    - PGGAN 베이스라인 아키텍처의 성능 향상
    - Disentaglement 특성 향상 (다양한 특징들이 잘 분리되어 있는 것)
- 특징 제어가 어려웠던 PGGAN의 단점 개선

---

## Batch normalization vs Instance normalization

- **Normalization**

$$\gamma \frac{x - \mu(x)}{\sigma(x)} + \beta$$

normalization의 식의 형태는 모두 비슷한데, 평균과 표준편차를 어떻게 구하는가가 달라진다.

- **Batch normalization**

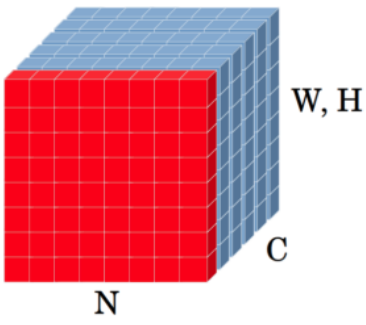

Batch Normalization

- N, H, W에 대해서만 연산을 진행한다.
- 미니 배치(빨간색 부분)의 모든 훈련 샘플에 걸쳐 하나의 채널에서 작동한다.

  → channel map C 와 무관하게 계산되어 batch N에 대해 normalization 된다.
- batch 단위별로 데이터가 다양한 분포를 갖더라도 평균과 분산을 활용하여 정규화한다.
- gradient vanishing과 exploding 문제를 방지한다.
- batch size가 작을 경우 좋지 않다.

- **Instance normalization**

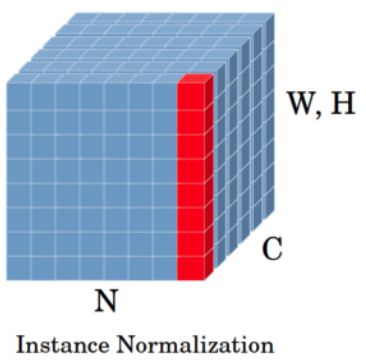

Instance Normalization

- x가 N개의 이미지 묶음으로 구성된 tensor라고 할 때, 이미지 각각은 H , W의 C feature map을 가지고 있다.
- 평균과 표준편차는 batch와 channel과 무관하게 각 데이터(W, H)에 대해서만 normalization을 진행한다.
- 각 데이터마다 normalization을 따로 하고, filter들의 종류와도 관계 없이 normalization을 진행한다.
- image style transfer 성능 향상을 위해 등장한 방법이다.
- Instance normalization 논문에서는 실험적으로 batch normalization보다 instance normalization을 사용했을 때 성능이 향상됨을 보였다.

---

## StyleGAN 구조

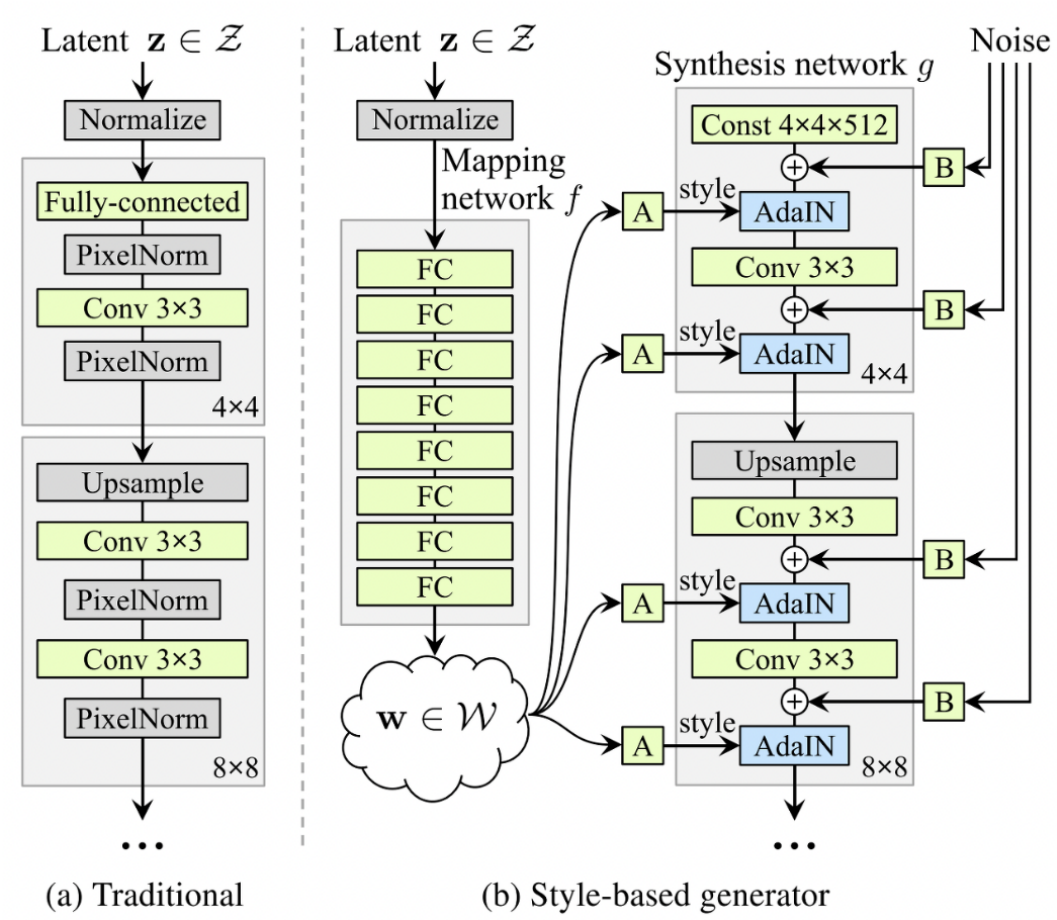


- **Style Mixing (Mixing regularization)**

  latant z를 바로 학습시키는 것이 아니라, multi latent z(w1, w2)를 이용하여 w 벡터를 만든 후 학습시킨다.

  → 다양한 style이 섞여서 synthesis network 학습이 된다.

  인접한 layer 간의 style 상관관계를 줄인다.

---

- **Mapping Network**

  가우시안 분포에서 샘플링한 z 벡터를 직접 사용하지 않고, 매핑 네트워크를 거쳐 w 벡터로 바꾼 후 이미지를 만들면 (b) 처럼 특정 분포를 따라야 하는 제한이 사라지기 때문에 (c) 처럼 각각의 특징을 훨씬 잘 분리할 수 있다.

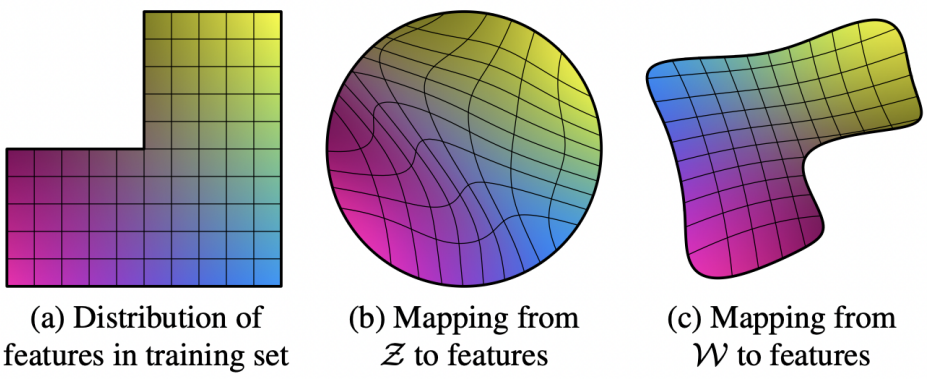

(a) Distribution of features in training set | (b) Mapping from $\mathcal{Z}$ to features | (c) Mapping from $\mathcal{W}$ to features

---

- **AdaIN(Adaptive Instance Normalization)**

  layer을 거치면 학습이 불안정해져서 normalization을 각 layer에 추가

  다른 원하는 데이터로부터 style 정보를 가져와 현재 이미지 style에 적용할 수 있음 (학습시킬 추가적인 파라미터가 필요하지 않고, 성능이 더 좋음)

  +) Instance Normalization

  채널마다 정규화를 수행했던 Batch Normalization과 달리, 하나의 이미지에 대해 정규화를 수행

$$\mathrm{AdaIN}(\mathbf{x}_i, \mathbf{y}) = \mathbf{y}_{s,i} \frac{\mathbf{x}_i - \mu(\mathbf{x}_i)}{\sigma(\mathbf{x}_i)} + \mathbf{y}_{b,i},$$

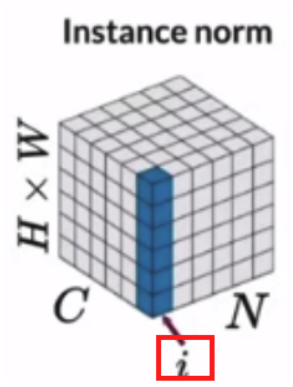


- ys : scale (style)
- yb : bias (noise)
- ys와 yb가 AdaIN 으로 겹겹이 import 된다.

▼ AdaIN code

```
'''
def g_block(input_tensor, latent_vector, filters):
  gamma = Dense(filters)(latent_vector)
  beta = Dense(filters)(latent_vector)

  out = UpSampling2D()(input_tensor)
  out = Conv2D(filters, 3, padding = 'same')(out)
  out = Lambda(AdaIN)([out, gamma, beta]) #Lambda는 API 모델을 구성할 때 임의 식을 계층으로 사용할 수 있도록 존재, 입력 텐서를 첫 번째 인수로 사용
  out = Activation('relu')(out)

  return out
'''

def AdaIN(x):
  #Normalize x[0] (image representation)
  mean = K.mean(x[0], axis = [0,1], keepdims = True)
  std = K.std(x[0], axis = [0,1], keepdims = True) + 1e-7
  y = (x[0] - mean) / std

  #Reshape scale and bias parameters
  pool_shape = [-1, 1, 1, y.shape[-1]]
  scale = K.reshape(x[1], pool_shape)
  bias = K.reshape(x[2], pool_shape)
  # ex) 8,8,64 -> 1,1,64

  #Multiply by x[1] (GAMMA) and add x[2] (BETA)
  return y * scale + bias
```

- y : 원하는 contents 이미지에서 contents 이미지의 스타일을 빼준 것
- y * scale + bias : 이미지의 스타일을 입혀준 것

## mean

```
keras.backend.mean(x, axis=None, keepdims=False)
```

Mean of a tensor, alongside the specified axis.

**Arguments**

- **x**: A tensor or variable.
- **axis**: An integer or list of integers in [-rank(x), rank(x)), the axes to compute the mean. If `None` (default), computes the mean over all dimensions.
- **keepdims**: A boolean, whether to keep the dimensions or not. If `keepdims` is `False`, the rank of the tensor is reduced by 1 for each entry in `axis`. If `keepdims` is `True`, the reduced dimensions are retained with length 1.

### reshape

```
keras.backend.reshape(x, shape)
```

Reshapes a tensor to the specified shape.

**Arguments**

- **x**: Tensor or variable.
- **shape**: Target shape tuple.

---

- **Noise**

  다양한 확률적인 측면 컨트롤 (ex. 주근깨, 머리카락 등)

  별도의 affine transformation인 B를 거쳐 각각의 feature map 마다 noise가 적용될 수 있도록 한다.

## StyleGAN 한계

물방울 형태의 blob 들이 관측

Figure 1. Instance normalization causes water droplet -like artifacts in StyleGAN images. These are not always obvious in the generated images, but if we look at the activations inside the generator network, the problem is always there, in all feature maps starting from the 64x64 resolution. It is a systemic problem that plagues all StyleGAN images.